

Magasiner sur eBay facilité par la
récolte automatisée du web

Magasiner sur eBay facilité par la récolte automatisée du web

Laurence Lemire

Université TÉLUQ

INF 1430 : Projet de fin d'étude

Résumé

Le présent travail détaille le développement d'une application utilisant la récolte d'information automatisée afin d'assister l'utilisateur pour le magasinage en ligne. On y détaille l'historique des pratiques informatiques d'exploration automatisée du web et de récolte automatisée du web. On y détaille aussi les implications légales et éthiques de ces pratiques et les problèmes qu'elles peuvent causer. On y détaille qu'on a développé le logiciel en suivant un modèle de programmation modèle-vue-contrôleur, et qu'on a utilisé les API et applications suivantes pour le développement de la solution : Java Swing, Selenium, JSON, FlatLaf et TwelveMonkeys. On explique qu'Amazon n'est pas supporté par le logiciel à cause de sa capacité à reconnaître les bots. On évalue le logiciel selon sa fonctionnalité, s'il est capable d'accomplir les tâches délimitées; son exactitude, si les informations qu'il affiche sont les mêmes que celles affichées sur la plateforme de vente; et sa vitesse de traitement de l'information. On explique pourquoi, selon ces critères, le logiciel est un succès et comment on pourrait encore l'améliorer.

Magasiner sur eBay facilité par la récolte automatisée du web

L'établissement du World Wide Web (WWW) dans les années 1990 a permis la normalisation du protocole HTTP afin de communiquer des informations sous un format plus uniforme. (Bergman & Popov, 2023) Depuis, ce protocole utilise l'Internet Protocol (IP) et le Transport Control Protocol (TCP) afin de transmettre des données telles que des pages web codées en HTML. (Bergman & Popov, 2023) Malgré toutes ses évolutions, il continue d'être compatible avec ses versions précédentes, donc toutes les requêtes d'information se font encore sous le format que la version 1.0 de HTTP utilisait, c'est-à-dire qu'il utilise encore les requêtes GET envoyées à des machines (ordinateurs ou serveurs) où les pages pointées par les URLs sont stockées. (Bergman & Popov, 2023) L'automatisation de l'envoi de ces requêtes GET à une URL et à toutes les URLs trouvées sur cette page de manière récursive est ce qu'on appelle le *web crawling* ou l'exploration du web automatisé. (Bergman & Popov, 2023) Le stockage des informations et données retrouvées sur ces pages web explorées est ce qu'on appelle le *web scraping* ou la récolte de pages web automatisée. (Khder, 2021) Les moteurs de recherche tels Google ont été les premiers explorateurs et récolteurs de pages web reconnus, puisqu'ils cherchent l'intégralité du web et compilent leur information en un index optimisant la récupération d'information. (Khder, 2021) Ce genre de récupération d'information à si grande échelle aurait pu sembler difficile à concevoir il y a quelques décennies, lors de l'avènement du protocole HTTP, mais celle-ci est possible grâce à la puissance des technologies modernes de l'information et au fait que toute information visualisable sur une machine peut être récupérée, stockée, nettoyée et utilisée à n'importe quelle fin par une autre machine. (Khder, 2021) La puissance des technologies modernes et du WWW permet aussi de générer des quantités massives de données non structurées quotidiennement, donc la récolte de page web est reconnue

comme étant une des meilleures techniques afin d'en extraire une grande quantité de données pertinentes et organisées pour l'analyse. (Asif et al., 2024; Khder, 2021)

Plus récemment, on peut remarquer l'augmentation de l'utilisation du magasinage en ligne, celui-ci est vraiment devenu un aspect fondamental de toutes entreprises. (Asif et al., 2024) On peut donc raisonnablement s'attendre à ce que les plateformes de cybercommerce se retrouvent aussi explorées et récoltées. Certaines des applications de récolte déjà développées permettent de récupérer la disponibilité d'un produit, les fluctuations de son prix, les avis des acheteurs, etc. (Dakov & Malinova, 2021) Ces informations sont nécessaires aux analystes et aux entreprises afin de mieux comprendre les tendances de consommation et de comportement de leurs clients et de développer un avantage compétitif afin de pouvoir garantir leur succès dans le domaine digital. (Asif et al., 2024; Lakshmi, 2023) Il existe quatre techniques principales utilisées pour collecter de l'information sur les cybercommerces : l'utilisation de fiche technique contenant les détails à propos d'un produit fournit par la plateforme de vente, l'utilisation de fils RSS, l'utilisation d'API natif à la plateforme de vente ou externe, et finalement la récolte automatisée de page web. (Dakov & Malinova, 2021) Les données récoltées sur les plateformes de cybercommerce peuvent être divisées en trois grandes catégories: les données des clients, comme leur appartenance démographique, leurs intérêts, leur historique d'achat, etc.; les données des produits, comme l'éventail des prix, leur disponibilité, leur vendeur, etc.; et les données des transactions, comme les méthodes de paiement utilisées, les frais d'envoi et les taxes appliquées. (Dilmegani, 2024) Puisque ces données peuvent changer de minute en minute et peuvent être pertinentes pour les acheteurs potentiels autant que pour les compétiteurs (Dakov & Malinova, 2021), il n'est pas étonnant que beaucoup d'entre eux se tournent vers la récolte d'information automatisée afin de ne pas avoir à constamment manuellement rafraichir des pages web. Ce

document cherche à présenter la création d'un récolteur d'information automatisé qu'un acheteur pourrait créer à cette fin. On y explicite les paramètres dans lesquels le logiciel fonctionne ainsi que les limites qu'on peut s'attendre à avoir à imposer à un tel logiciel. On y présente aussi les enjeux légaux et éthiques de ce genre de pratique.

Revue littéraire des pratiques informatiques concernées

La composition des pages web

Comme expliqué plus haut, le protocole HTTP permet la communication de page HTML entre les machines. L'HTML (HyperText Markup Language) « est un langage descriptif qui définit la structure d'une page web. » (Mozilla, 2023) Il est structuré dans un document par des éléments encadrés de balises ouvertes et fermantes les définissant. (Mozilla, 2023) Un fichier HTML (dont l'extension est .htm ou .html) est rendu disponible sur un serveur et affichable sur un navigateur web, ce qui permet d'en extraire de l'information. (Khder, 2021; Mozilla, 2023) Cependant, les balises qui définissent les éléments dans le fichier HTML ne sont pas toutes régies par une norme, rendant le contenu de la page largement non structuré, ce qui rend l'extraction d'information plus difficile et moins uniforme. (Khder, 2021) De plus, les navigateurs ne proposent pas de manière facile d'exporter leurs données dans la majorité des cas, ce qui rend la tâche encore moins uniforme et normalisable. (Khder, 2021) Ceci impacte aussi toutes données de produits de cybercommerce, dont les métadonnées disponibles changent de format et présentation de site en site, forçant ainsi le développement d'analyseur et de récolteur différent pour chaque plateforme de cybercommerce. (Dakov & Malinova, 2021)

Ces analyseurs et récolteurs sont différents types de bot, c'est-à-dire des logiciels autonomes qui agissent sur un réseau, dans ce cas l'Internet, et peuvent interagir avec d'autres machines. (Khder, 2021) Le bot est ce qui explorera et récoltera les pages web afin de récupérer

des données. (Khder, 2021) La récolte automatisée du web demande donc l'implémentation de deux logiciels : un explorateur, qui télécharge systématiquement les données depuis l'Internet; et un récolteur, qui extrait de ces données les informations importantes, les encode et les stocke dans une base de données ou un fichier selon un format défini par le créateur du bot. (Khder, 2021) Ceci permet aux données enregistrées d'être utilisées d'une manière que les données brutes rendaient impossible. (Khder, 2021) L'utilisation d'un tel bot permet la récupération d'information à faible coût à une très haute fréquence, et permet de générer des ensembles de données habituellement plus détaillés que ceux rendus disponibles par les propriétaires des plateformes ou par les autorités responsables de ce domaine. (Khder, 2021)

L'exploration du web automatisée (*web crawling*)

Les explorateurs du web automatisé, aussi appelés araignées, sont un type de bot qui explore une collection de sites web (voir même l'Internet en entier), localisant le contenu recherché et indexant le domaine où il se trouve afin de pouvoir éventuellement le récolter avec un récolteur de web automatisé. (Khder, 2021; Morello, 2024) Ils peuvent aussi télécharger le contenu d'une page web afin d'en extraire les hyperliens présents et de les ajouter à la collection de sites web à explorer de façon récursive. (Thelwall & Stuart, 2006) Il existe un grand nombre de logiciels d'exploration automatisée disponibles sur le marché, chacun se concentrant sur un aspect différent de l'exploration automatisée. Certains se concentrent sur l'acquisition de contenu à des fins d'enquêtes criminelles, d'autres sur l'amélioration de la performance durant l'exploration de plus grande quantité de pages, et d'autre encore se spécialisant dans les pages du web sombre, où les communications se font sur des réseaux souvent anonymes et cryptés afin de minimiser la traçabilité des utilisateurs. (Thelwall & Stuart, 2006) Leur performance n'est pas

seulement mesurée par leur vitesse d'exécution, qui peut atteindre en moyenne 0.46 page par secondes, mais aussi par leur efficacité et leur exactitude. (Bergman & Popov, 2023)

Les premiers explorateurs automatisés ont probablement été programmés par des informaticiens informés des caractéristiques des réseaux qu'ils exploraient et donc des impacts de leur exploration automatisée. (Thelwall & Stuart, 2006) De ce fait, la majorité des explorateurs automatisés modernes destinés au grand public sont recommandés d'être limités par l'application du protocole robots.txt. (Thelwall & Stuart, 2006) Ce protocole permet au propriétaire d'un site de fournir des instructions à l'explorateur automatisé dans un fichier nommé robots.txt qui limite quelles parties du site le bot peut explorer. (Thelwall & Stuart, 2006) Certains moteurs de recherche ont même ajouté au fichier des instructions imposant un délai entre chaque exploration afin de ralentir les explorateurs automatisés. (Thelwall & Stuart, 2006) Le protocole a été développé afin de protéger les propriétaires de sites web de la surutilisation de leurs ressources (serveurs et réseaux) si leur site se retrouvait à être exploré automatiquement, et afin d'empêcher l'indexation de contenus indésirable (tel que des parties privées ou inachevées d'un site) par les moteurs de recherches. (Thelwall & Stuart, 2006) Cependant, le protocole ne permet pas de contrôler d'autres aspects de l'exploration automatisés, tels que la vitesse d'exploration ou la quantité de pages qu'un bot peut demander à la fois. Il existe des recommandations informelles à ce sujet qui cherche à protéger les serveurs web d'être surmenés par les explorateurs automatisés, mais aucune standardisation n'existe pour l'instant, donc il est recommandé que chaque programmeur s'interroge au sujet des limites raisonnables qu'il doit imposer à son bot afin de minimiser son impact sur les serveurs propriétaires, et que chaque propriétaire s'interroge sur la possibilité d'ouvertement partager ses données afin de minimisé la nécessité de l'exploration automatisée. (Thelwall & Stuart, 2006) L'application du protocole

robots.txt est un aspect des explorateurs automatisés que les programmeurs de bot peuvent contrôler, mais certains autres aspects, tels que la vitesse de l'Internet, sont hors de leur contrôle. (Thelwall & Stuart, 2006) Il existe quatre grandes catégories de problèmes que les explorateurs automatisés peuvent créer : le déni de service, le coût, la vie privée et le droit d'auteur. (Thelwall & Stuart, 2006)

Déni de service (Denial of Service – DOS)

Un déni de service est un type d'attaque informatique où l'attaquant perturbe les connexions entre deux machines ou sature le réseau avec une grande quantité de requêtes et d'informations jusqu'à ce qu'il se mette hors service. (de Mereuil & Bonnefous, 2016) Dans le cas d'un explorateur automatisé du web, l'explorateur devient l'attaquant accidentel. Il va surcharger le réseau et le serveur hôte avec trop de requêtes en trop peu de temps, jusqu'à ce que celui soit incapable de répondre à ces requêtes dans un délai raisonnable. Le problème survient quand le serveur ou le réseau est tellement occupé à répondre aux requêtes d'un bot qu'ils se retrouvent incapables d'accomplir leur mission initiale, soit de répondre aux requêtes de vrais utilisateurs dans un délai raisonnable. (Thelwall & Stuart, 2006) Afin de minimiser ce problème, il suffit de porter attention à la fréquence et la vitesse des requêtes envoyées par le bot. Ces notions invoquent l'idée d'une vitesse d'exploration raisonnable. Cependant cette vitesse ne peut pas être codifiée formellement puisqu'elle évolue avec les avancées technologiques, rendant ce problème moins critique que lors de l'avènement de l'exploration automatisé. (Thelwall & Stuart, 2006) On recommande donc en général que l'explorateur automatisé travaille à une vitesse appropriée pour la capacité des réseaux et des serveurs auxquels il fera appel, ce qui rend ce problème moins commun pour des explorateurs automatisés de petite envergure utilisés par des consommateurs individuels qui seront de toute façon limités par leur propre réseau et leur

propre ordinateur. (Thelwall & Stuart, 2006) Alternativement, on peut aussi implémenter une règle forçant les explorateurs automatisés à n'accéder à une page que si celle-ci à changer depuis le dernier accès tel qu'indiqué par l'en-tête HTTP, ce qui réduira grandement la quantité de requêtes redondantes envoyées aux réseaux et serveurs hôtes. (Thelwall & Stuart, 2006)

Coût

En ce qui concerne les impacts sur le coût, ceux-ci sont principalement causés par les limitations imposées à la bande passante des réseaux et serveurs hôtes. (Thelwall & Stuart, 2006) Si un site web excède la limite mensuelle de sa bande passante, son propriétaire peut se voir forcé à payer des frais supplémentaires, ou peut même voir son site désactivé. (Thelwall & Stuart, 2006) Malheureusement, il n'est pas possible d'empêcher le trafic des bots afin de prévenir ce genre de coût, puisque les bots peuvent se rendre indistinguables des utilisateurs ordinaires, mais il est possible pour les programmeurs de bot de considérer comment leurs actes peuvent influencer les propriétaires de sites web. (thebotmaker, 2024; Thelwall & Stuart, 2006) Il importe donc aux programmeurs de considérer comment leur exploration automatisée bénéficie directement aux propriétaires afin de rendre la perte monétaire potentielle valable. (Thelwall & Stuart, 2006) Sinon, on encourage l'implémentation d'une stratégie d'exploration automatisée informée par le type de serveur et de réseau exploré de telle sorte à ce que les serveurs plus coûteux ne soient pas explorés ou soient explorés plus lentement ou moins souvent. (Thelwall & Stuart, 2006)

Vie privée

Les enjeux de vies privées ne devraient pas être difficiles à éviter puisque toutes les informations se retrouvant sur le Web sont considérées comme dans le domaine public. (Thelwall & Stuart, 2006) Cependant, certaines combinaisons d'informations identificatrices

peuvent tout de même être soumises aux lois sur la vie privée si elles sont utilisées dans certains scénarios, rendant la situation particulièrement complexe pour les recherches où le consentement éclairé des individus à qui ces informations font référence interférerait avec l'objectif de recherche. (Thelwall & Stuart, 2006) L'approche éthique serait donc de considérer les impacts sur la vie privée de l'exploration sans tenir pour acquis si les propriétaires des pages prenaient des décisions pour l'intérêt de leur propre vie privée ou non. (Thelwall & Stuart, 2006) Il est aussi important de prendre en compte la relation de pouvoir entre les explorateurs et les propriétaires de sites, où les propriétaires pourraient être contraints de participer à un projet de recherche passivement alors qu'ils auraient pu rester ignorants à l'exploration automatisée faite à leur site. (Thelwall & Stuart, 2006)

Droit d'auteur

Il semble clair que les explorateurs de web automatisé enfreignent le droit d'auteur puisqu'ils créent et stockent des copies permanentes de matériaux sous droit d'auteur, les pages web explorées, sans nécessairement recevoir la permission des propriétaires du site et/ou du matériel en question. Cependant, cette question est plus complexe qu'à première vue, et elle sera discutée en plus grands détails dans la section portant sur les enjeux légaux et éthiques de ces pratiques.

La récolte de page web automatisée (*web scrapping*)

Comme expliqué plus haut, la récolte de page web automatisée fait référence à l'extraction systématique de l'information non structurée présente sur une page web et de sa transformation en données structurées utilisables, par exemple un fichier Excel ou CVS ou JSON. (Asif et al., 2024; Dakov & Malinova, 2021; Khder, 2021; Morello, 2024; Perez, 2020) Le processus de récolte d'information se décline en trois grandes phases : l'accès à la page web,




Figure 1. Processus d'exploration (1) et récolte (2, 3, 4) automatisé du web (Asif et al., 2024)

extraction de l'information, puis la transformation des données en un format structuré, utilisable et stockable dans une base de données. (Khder, 2021) Les techniques utilisées pour récolter l'information peuvent être aussi simples et lentes que de copier-coller manuellement les informations visualisables sur la page, et peuvent être aussi complexes et rapides que de programmer une liste d'instructions précises dans un bot de récolte automatisée afin de n'extraire que les quelques caractères recherchés. (Dakov & Malinova, 2021; Khder, 2021; Mancosu & Vegetti, 2020; Perez, 2020) Plus précisément, la récolte d'information peut se faire par copier-coller, ce qui est plus pratique lors de la collecte de peu de données, mais devient rapidement long et pénible dès que la quantité de données à collecter augmente; par la sélection de texte et d'éléments par expression régulière (*RegEx*), ce qui est une méthode simple basée sur la capacité de l'ordinateur à comprendre et associer les expressions régulières; par l'analyse d'HTML, le langage composant la page web étant semi-structuré ce qui rend l'analyse relativement facile; par analyse du DOM (*Document Object Model*), ce qui permet d'accéder à toutes les fonctions des

navigateurs web et aux éléments dynamiques disponibles du côté client des pages web; par l'utilisation d'un logiciel de récolte automatisé du web, ce qui permet de personnaliser la manière dont la récolte d'information sera faite si le logiciel est développé par l'utilisateur, ou, dans le cas de logiciel disponible sur le marché, ce qui permet de ne pas avoir à créer de script ou d'instruction puisque le logiciel identifie par lui-même la structure de la page et peut même enregistrer l'interface; et, finalement, par analyseur par vision par ordinateur, ce qui permet à l'ordinateur de visualiser la page web comme un humain et d'utiliser l'apprentissage machine pour découvrir et récolter les informations pertinentes. (Khder, 2021) L'usage d'un récolteur automatisé permet à l'usager de sélectionner les sites web desquels il souhaite extraire les informations et de bâtir leur projet afin d'en extraire seulement les données dont il a besoin ou la page en entier à un relativement faible coût en argent et en ressource. (Asif et al., 2024; Khder, 2021; Perez, 2020) Cependant, certains types de récolteurs automatisés qui travaillent avec de grandes quantités de sites et de données peuvent nécessiter énormément de ressources afin de bien fonctionner. (imperva, s. d.) Il existe certains types spécifiques de récolteurs automatisés qui se spécialisent dans un type de récolte d'information spécifique. Par exemple, un récolteur utilisant de la navigation automatisée est un récolteur qui émule les actions d'un utilisateur sur un navigateur, tel que l'écriture dans certains champs ou le clic de certains boutons ou liens. (Khder, 2021; Mancosu & Vegetti, 2020) Un récolteur d'écran automatisé est un type de récolteur automatisé qui, lui, copie et enregistre les pixels affichés à l'écran, alors qu'un récolteur automatisé standard analyse le fichier HTML affichant la page web afin d'en extraire des données. (imperva, s. d.) Dans tous les cas, si le site cible effectue des changements mineurs ou majeurs à son affichage ou ses métadonnées, l'efficacité du récolteur pourrait être proportionnellement affectée et celui-ci devra probablement être partiellement ou complètement

reconfiguré afin d'être capable de trouver les données recherchées. (Khder, 2021; Mancosu & Vegetti, 2020)

Les récolteurs automatisés sont principalement utilisés par : les moteurs de recherche (tel qu'expliqué plus haut), les compagnies de recherche de marchés, les compagnies avec beaucoup de compétitions, les chercheurs académiques, les archivistes de vieilles pages web, etc. (Dakov & Malinova, 2021; Khder, 2021) Dans un contexte de cybercommerce, les consommateurs et les compétiteurs auront tendance à faire de la récolte de page web automatisée afin de comparer les offres, viser leurs annonces, rechercher des produits, analyser le sentiment et les comportements des acheteurs, etc. (Dilmegani, 2024; Khder, 2021) Dans tous ces cas, un site sera plus susceptible à être récolté s'il fait compétition à d'autres entreprises, s'il est populaire et reçoit beaucoup de trafic, si la valeur qu'il ajoute à la société est unique ou essentielle, ou s'il contient une brèche de sécurité. (Khder, 2021) Un moyen efficace et relativement facile de décourager les récolteurs automatisés est de changer fréquemment l'organisation du fichier HTML sous-jacent, car la reconfiguration du récolteur afin de s'adapter aux changements peut demander énormément de temps et de ressources. (Dilmegani, 2024; Mancosu & Vegetti, 2020) Il existe aussi des techniques afin de protéger les sites de la récolte automatisée de leurs informations. Entre autres, les sites web peuvent utiliser une inspection plus détaillée des en-têtes HTML, ils peuvent utiliser un système de réputation des adresses IP, et ils peuvent mettre en place des défis reconnus pour leur facilité à être résolu par un humain et pour leur difficulté à être résolue par un ordinateur. (AWS, 2016; imperva, s. d.)

Un des moyens disponibles afin d'éviter l'usage de récolteur automatisé est la disponibilité d'un API (*Application Programming Interface*) de partage de données fourni par le site cible. Un API est un groupe de protocoles de communication et d'instructions qui

fournissent un accès aux données d'une application, d'un logiciel ou d'un système. (Perez, 2020)

Ceci permet aux utilisateurs d'extraire les données en très peu de requêtes dans un format déjà structuré (dans un fichier XML ou JSON par exemple) sans avoir à extraire des données non structurées du HTML du site en plusieurs requêtes différentes et à les manipuler afin de les rendre utilisables. (Khder, 2021) Ceci permet aussi au propriétaire de donner ses données à l'intérieur des limites qu'il établit (mettre les données derrière un verrou d'accès payant, limiter le nombre de requêtes par utilisateurs, limiter les données accessibles, etc.), mais ceci rend aussi les personnes utilisant ces données dépendantes du propriétaire et de sa bonne volonté afin de garder les données qui les intéressent accessibles à travers l'API et de garder l'API actif et accessible. (Mancosu & Vegetti, 2020; Perez, 2020) Il est possible de se retrouver dans un scénario où l'API fourni par le site cible ne contient pas les données recherchées, ou où le verrou d'accès payant est trop cher, et c'est dans ces cas qu'il peut devenir plus avantageux d'utiliser ou de créer un récolteur automatisé. (Khder, 2021; Perez, 2020) Une autre raison pour laquelle un API, ou un service similaire, n'est pas toujours une solution viable est dans le cas d'une enquête sur les pratiques et les comportements des utilisateurs d'une plateforme qui aurait la possibilité de prouver que les propriétaires du site visé facilitent des phénomènes nocifs allant à l'encontre de leurs propres termes d'utilisation. (Mancosu & Vegetti, 2020) Par exemple, Facebook a décidé de retirer leur API de partage de données qui était autrefois disponible aux chercheurs et a décidé à la place de rendre les informations accessibles à travers des demandes faites directement à une organisation tierce. Cependant, si les informations demandées avaient la chance de prouver que Facebook facilitait les comportements violent et abusif en ligne (tel que la désinformation, les discours haineux et l'incitation à la violence et l'abus), il ne serait pas dans l'intérêt de Facebook de fournir ces renseignements en pleine transparence, ce qui ensuite limite le type de

recherche qui peut être effectué sur cette plateforme. (Mancosu & Vegetti, 2020) Il devient donc essentiel pour les chercheurs d'accéder à ces données par récolte automatisée s'il souhaite avoir un aperçu plus objectif de l'état des choses, ce qu'ils doivent faire prudemment considérant les potentielles violations des conditions d'utilisations. (Mancosu & Vegetti, 2020) Bref, il existe plusieurs raisons pour lesquels il est préférable de s'en tenir à la récolte automatisée et de ne pas utiliser un API : si le site web ciblé ne fournit pas un API, si l'API ne fournit pas les données dont on a besoin, et si l'accès à l'API est trop limité pour l'utilisation qu'on souhaite en faire (en termes de requêtes et en termes monétaire). (Khder, 2021)

L'utilisation d'un récolteur automatisé peut tout de même être difficile. En effet, il existe plusieurs techniques afin de contrer la récolte automatisée, telles que les CAPTCHAS, que les plateformes peuvent implémenter afin d'assurer que les machines se connectant à leur réseau sont opérées par des humains et non des bots, et le masquage de données réelles si le site croit que son visiteur est un bot. (Dilmegani, 2024; Mancosu & Vegetti, 2020) Ces difficultés peuvent être facilement déterminées comme étant moins importantes que les avantages que la récolte automatisée fournit. En effet, la récolte automatisée est considérée comme plus efficace, rapide, cohérente et facile à opérer et maintenir que de demander à un humain de récolter manuellement l'information de façon répétitive, ce qui permet aux entreprises de sauver du temps, des ressources et de l'argent, tout en leur permettant d'obtenir un avantage compétitif afin de mettre à jour leurs prix en temps réel. (Khder, 2021; Radware, 2022) Certains sites de comparaison de prix de cybercommerces sont même tolérés par les entreprises malgré leur usage de récolteurs automatisés, car ils fournissent éventuellement un bon trafic vers les plateformes de cybercommerces qu'ils comparent. (Radware, 2022) De plus, plusieurs études ont été faites afin d'explorer l'usage de différentes méthodes de récolte automatisée et de différents langages de

programmation afin de rendre la récolte automatisée plus efficace et de contourner les méthodes anti-récoltes constamment en évolution utilisée par les sites qui ne veulent pas être récoltés. (Khder, 2021)

Les enjeux éthiques et légaux de ces pratiques

Il est important de préciser qu'aucune technologie n'est inhéremment bonne ou mauvaise, leurs impacts dépendent de leur usage et la manière dont ils sont intégrés à la société. (Thelwall & Stuart, 2006) La nouveauté des technologies informatiques engendre de nouvelles interrogations morales dont les solutions ne sont pas facilement déguisables à cause du manque d'encadrement moral clairement applicable à ces nouveautés. (Khder, 2021; Thelwall & Stuart, 2006) Certaines technologies, comme les innovations médicales, sont entourées de cadres éthiques et légaux dès le début de leur création, mais d'autres, comme l'Internet, se développe dans un monde sans régulations claires, ce qui pousse ses utilisateurs à explorer les limites avant que le cadre légal et éthique ne soit prêt à efficacement limiter les usages nocifs. (Thelwall & Stuart, 2006) Malheureusement, dans le cas de la récolte d'information automatisée, les implications légales et éthiques sont souvent mises de côté et ignorées, et les décisions des cours ne sont pas encore assez nombreuses (et dépendent souvent trop de faits spécifiques au cas étudié) afin de facilement déduire les limites imposées par les lois pour ces pratiques. (Khder, 2021)

En général, la récolte d'information automatisée est considérée légale si les informations récoltées sont disponibles au grand public, ne sont pas sous un droit d'auteur et ne constituent pas un bris de la vie privée. (Bettenbuk, 2021; imperva, s. d.; Morello, 2024) Cependant, si le contenu récolté est collecté sans la permission du propriétaire ou si cette récolte est clairement et explicitement interdite dans les conditions d'utilisation d'un site, ou encore si l'exploration et la

récolte d'information causent un site ou un service à tomber hors d'usage, la pratique pourrait être reconnue comme illégale par la cour. (Khder, 2021; Morello, 2024) De plus, l'utilisation qui sera faite des données récoltées impacte grandement la détermination de la légalité de la récolte d'information. Par exemple, lors du cas de HiQ vs LinkedIn, la cour décida que les données récoltées sur un site web ne violaient pas les lois antipiratage tant que les données étaient publiques et que le récolteur d'information n'avait pas déjà accepté les conditions d'utilisation du site ciblé. (Bettenbuk, 2021) Il est possible pour des récolteurs malintentionnés de récolter des sites web en entier afin de faire passer ces données comme les leurs, malgré le fait que la majorité des sites web interdisent le téléchargement direct de leur contenu et le stockage de ces copies illégales sur des machines locales. (Khder, 2021) En ce qui a trait à la vie privée, on peut prendre en exemple les données extraites de Facebook, qui doivent ne contenir aucune information avec lesquels on pourrait identifier les individus faisant partie de l'ensemble de données et qui ne doivent contenir aucune information privée à propos des utilisateurs afin d'être considérées légalement et éthiquement acceptables. (Mancosu & Vegetti, 2020) Il existe d'autres cas plus précis de comportements illégaux utilisant la récolte d'informations automatisée: la récolte de prix automatisé, qui peut mener à des pertes monétaires importantes pour les commerces où les informations ont été récoltées afin de proposer leur produit à un meilleur prix, et la récolte de contenu automatisé, où de grandes quantités de contenu (comme des bases de données) sont volées à un site web afin d'être distribuées illégalement ou d'être revendues à un compétiteur. (imperva, s. d.) Bref, les principales questions à se poser sont : Est-ce que des informations personnelles sont récoltées?, Est-ce des informations sous droit d'auteur sont récoltées?, et Est-ce les données récoltées sont protégées par une authentification? (Bettenbuk, 2021)

D'un point de vue éthique, il est plus important de considérer les impacts que la récolte automatisée aura sur toutes les parties prenantes plutôt que les limites strictement légales. (Thelwall & Stuart, 2006) Un récolteur automatisé est considéré éthique s'il minimise les désavantages et augmente les bénéfices potentiels au point où les bénéfices nets sont plus grands ou égaux à tout autre plan d'action. (Thelwall & Stuart, 2006) Ceci peut être difficile à évaluer, car la portée des actions n'est pas toujours claire et évidente. Une des manières les plus basiques de respecter les limites d'un site ciblé est en respectant le protocole robots.txt. du site, celui-ci permettant au propriétaire d'établir les limites à l'intérieur desquels il considère la récolte automatisée avantageuse pour lui-même, ce qui donne au récolteur un niveau d'assurance que ses actions ne créent pas plus de tort que de bien pour le propriétaire des données récoltées. (Khder, 2021) Il est surtout important de prendre des décisions au cas par cas, à la récolte par récolte, car chaque récolte automatisée dépend de trop de facteurs et de participants qui varient pour chaque récolte individuelle, et l'évaluation individuelle de chacun d'être eux est nécessaire à chaque récolte. (Thelwall & Stuart, 2006) En ce qui concerne la consommation de ressource, il peut être stratégique d'utiliser des services infonuagiques afin de regrouper des instances de récolte automatisée et de les faire fonctionner en parallèle afin d'obtenir des résultats rapidement sans surcharger un seul site de requêtes. (Khder, 2021) Il est aussi important pour les entreprises de se questionner sur leur position éthique en ce qui concerne la récolte de leurs données ainsi que leur récolte des données externes à leur entreprise, surtout lorsque leurs pratiques pourraient les pousser vers des litiges éthiques et des procès. (Khder, 2021)

Le cas d'eBay

Les conditions d'utilisation d'eBay citent explicitement que les utilisateurs qui consentent à ces conditions n'utiliseront pas d'explorateur ou de récolteur automatisé ni aucun autre bot

permettant l'extraction de données ou d'accès aux services automatisé à moins d'avoir reçu la permission préalable d'eBay. (eBay, s. d.-a) Cependant, les seules conséquences qu'eBay peut appliquer si ces conditions sont violées sont de restreindre les activités du compte de l'utilisateur qui a violé les conditions, et éventuellement de le suspendre. (eBay, s. d.-b) Dans les faits, ils n'ont pas de méthode réelle d'appliquer des conséquences si le récolteur ne récolte pas d'information en étant authentifié dans un compte utilisateur ou n'a pas de compte eBay à son nom. De ce fait, ils utilisent certaines méthodes anti-récolte automatisées s'ils ont l'impression qu'ils reçoivent trop de requêtes suspectes, telles que des CAPTCHAs, des blocs ou des délais dans leurs réponses, le blocage de certaines adresses IP, etc. (AdsPower, 2024)

Méthodologie de développement logiciel

Buts et attentes du logiciel

Par le passé, d'autres logiciels ont été créés afin de suivre différents items sur une plateforme de cybercommerce et de comparer leurs prix. Ces logiciels utilisaient aussi de la récolte d'information automatisée sous différentes formes. Puisque les cybercommerces n'utilisent pas une représentation standard des données de leurs produits, chaque logiciel doit développer un analyseur pour chaque plateforme d'où il souhaite extraire de l'information. (Dakov & Malinova, 2021) Le projet de (Dakov & Malinova, 2021), par exemple, utilisait des

- Visualiser les articles en mémoire,
- Entrer un nouvel article dans la liste,
- Modifier un article existant dans la liste,
- Supprimer un article de la liste,
- Mettre à jour les prix des articles.

Figure 2. Liste des tâches à compléter avec le logiciel

requêtes HTTP pour accéder à l'information, et il était entre autres possible pour leur utilisateur de fournir des liens vers des produits dont l'analyse n'était pas encore supportée dans leur logiciel. Dans ce cas, le produit était tout de même stocké dans la mémoire du logiciel, mais il était affiché comme étant non supporté. (Dakov & Malinova, 2021)

Notre projet s'inspire des fonctions disponibles dans ces projets précédents. Le logiciel devra être capable de récolter le nom, le prix courant et l'image du produit dont l'URL est fournie par l'utilisateur. Il devra afficher ces informations ainsi que la description entrée par l'utilisateur dans une fenêtre qui affichera toutes ces informations pour tous les produits. Le logiciel devra permettre à l'utilisateur d'ajouter un nouvel item à la liste et de modifier les informations des items déjà présents dans la liste. Il devra aussi permettre aux utilisateurs de supprimer un item de la liste. Le logiciel devra ensuite sauvegarder toutes ces informations pour tous les items dans un fichier mémoire afin de pouvoir conserver les items en mémoire entre les utilisations du logiciel. Il devra aussi mettre à jour les informations qu'il collecte par récolte automatisée des URLs des items de la liste. Ces mises à jour pourront être déclenchées manuellement ou être effectuées automatiquement sur un délai personnalisable. À travers toutes




Figure 3. Composantes de base du logiciel

ces données, le logiciel devra s'assurer que la liste ne contient jamais deux items dont l'URL pointe sur le même article. D'un point de vue cosmétique et ergonomique, le logiciel devra avoir un mode sombre fonctionnelle, où les composantes ont une palette de couleurs cohérente.

Cadre/API/paquetages/IDE utilisés

Le modèle de programmation Modèle-Vue-Contrôleur (MVC) est un modèle qui a pour but de diviser le programme en modules pour le modèle, les vues et le contrôleur. (Gouin-Vallerand & Ruer, 2015a) Par le modèle, on entend les composantes qui vont servir à la gestion et au stockage des données. Il va permettre à l'application d'accéder au fichier mémoire et de le modifier selon les actions prises dans l'application. Les vues désignent toutes les composantes qui affichent les données aux utilisateurs. On pense, par exemple, aux composantes de l'interface graphique (*graphical user interface*, GUI) qui changent et se déplacent selon les besoins de l'utilisateur et de l'application. Ses seules tâches sont d'afficher les données fournies par le modèle et de récupérer les données entrées par l'utilisateur grâce à ses composantes graphiques. Le contrôleur sert d'intermédiaire entre les vues et le modèle. Il connaît les besoins des vues et sait comment manipuler et traduire les données du modèle pour les rendre accessibles aux vues, et donc à l'utilisateur. Il connaît aussi les besoins du modèle et sait traduire les entrées de l'utilisateur par les vues afin de les rendre compatibles avec le modèle. Grâce à sa connexion à




Figure 4. Représentation du modèle MVC (Bouchard, 2007)

toutes ces composantes, il peut avertir les vues de tous changements au modèle qui les forceraient à modifier leur affichage.

Le modèle MVC permet de travailler sur les interfaces sans à avoir à modifier le modèle de gestion, manipulation et stockage de données. Il encourage et force la conception de logiciel modulaire, ce qui permet d'ajouter et de retirer des modules sans rendre l'application complètement inopérable et ce qui permet le développement en parallèle d'autres modules. Finalement, ce modèle encourage une conception plus claire et compréhensible, ce qui facilite l'entretien et le développement du logiciel. (Gouin-Vallerand & Ruer, 2015a)

Pour la création et la génération des interfaces graphiques, des vues du modèle, on a choisi l'API Java Swing. Cet API permet de facilement coder et manipuler les composantes d'interfaces graphiques, particulièrement à travers l'IDE NetBeans, qui permet de construire l'interface graphique de manière intuitive en manipulant directement les composantes graphiques sans avoir à générer manuellement le code associé. Java Swing permet donc de produit un GUI ergonomique rapidement et facilement.

On a choisi l'application FlatLaf afin d'harmoniser l'apparence (*look & feel*) de l'application. (Tauber, 2024) Cette application peut être utilisée dans n'importe quel logiciel utilisant Java Swing afin de rhabiller toutes les composantes graphiques de l'application pour qu'elles aient une apparence plus moderne. Il permet aussi de facilement implémenter un mode sombre où les composantes continuent d'avoir une apparence cohérente entre elles sans avoir à coder manuellement chaque couleur pour chaque composante.

Ensuite, pour permettre l'accès aux pages contenant l'information des articles d'intérêt, on a choisi l'API Selenium. Cet API permet l'accès à une page web par la récolte d'écran automatisé. Cet API a été développé afin de tester par automatisation des pages web afin de les

déboguer. (Asif et al., 2024; Bergman & Popov, 2023) Il accomplit cette tâche en ouvrant un navigateur web et en interagissant avec celui-ci similairement à un humain, qui peut interagir avec des éléments dynamiques de la page, cliquer sur des boutons et entrer du texte. (Asif et al., 2024; Bergman & Popov, 2023; Khder, 2021) Sa capacité à lire et manipuler les pages web lui permet aussi d'être un bon outil pour la récolte automatisée, surtout puisqu'il permet un grand niveau de personnalisation pour sa configuration et son interaction avec les pages web et qu'il permet à son utilisateur de voir chaque page qui est ouverte et combien de temps le logiciel passe à récolter l'information sur chaque page visitée. (Acuña, 2022; Asif et al., 2024; Bergman & Popov, 2023) Cependant, l'ouverture et la fermeture de toutes ces pages peuvent rendre le processus de récolte considérablement plus lent et lourd pour l'ordinateur qui opère le logiciel que d'autres techniques de récolte automatisée. (Bergman & Popov, 2023) Bref, même si ce n'était pas son but original et qu'il n'est pas l'option la plus optimale, il rend la tâche facile et intuitive à coder. L'API est capable d'extraire les informations des produits, tels leur nom, leur prix et leur description, facilement afin de toujours avoir l'information la plus récente qui serait visible à l'utilisateur s'il visitait le site lui-même. (Asif et al., 2024) Ceci permet de ne pas dépendre de l'API de récolte de données fournit par la plateforme, car cela pose un danger au long terme si la plateforme change le fonctionnement de son API ou cesse son utilisation (Mancosu & Vegetti, 2020), et de ne pas avoir à télécharger de pages complètes en HTML puis devoir passer à travers chacune d'entre elles avec un analyseur hors-ligne, ce qui est très demandant en mémoire et en pouvoir de traitement nécessaire. (Perez, 2020)

L'API JSON a été choisi pour le stockage des données des items de la liste d'article d'intérêt sur la machine local où le logiciel est utilisé. Cet API sert à la création et la manipulation de fichier JSON dont le format est normalisé et facile à lire autant pour le logiciel

que pour l'humain. Il permet donc un accès facile et rapide aux informations tout en étant moins difficile à lire et écrire qu'un fichier texte ou XML. Il permet aussi de stocker les informations entrées par l'utilisateur et récoltées par Selenium pendant les utilisations du logiciel afin de les garder en mémoire entre ces utilisations.

Durant les tests faits sur l'application, on a ajouté la librairie TwelveMonkeys ImageIO afin d'assurer l'affichage des images dans le logiciel même lorsque ces images étaient d'un format non natif à Java et Java AWT, qui est la librairie responsable de lire et afficher les images dans le logiciel. (Kuhr, 2024)

Finalement on a utilisé l'application Launch4j afin d'emballer le fichier .jar résultant de la compilation de l'application en un fichier exécutable d'application utilisable sur un bureau Windows. (Kowal, 2022) Ceci a permis d'unifier la distribution du logiciel lors des évaluations.

Limites imposées au logiciel

Il existe un grand nombre d'obstacles à la récolte automatisée, tel qu'expliqué plus haut, des limites imposées par la machine qui fait la récolte, en termes de vitesse de traitement et de taille de la mémoire, aux limites imposées par la plateforme d'où les données sont récoltées, comme les mesures anti-récolteur automatisé et les limites du débit. (Khder, 2021)

Détecteur de bot d'Amazon

Lors de la finalisation d'un des prototypes, on s'est retrouvé bloqué par le détecteur d'automatisation d'Amazon. En effet, comme expliqué plus haut, certaines plateformes de cybercommerce cherchent à minimiser le pouvoir des revendeurs et de leurs compétiteurs en les empêchant d'automatiser leurs opérations. (Khder, 2021) De plus, ils peuvent déclarer l'usage de techniques contournant leurs protections comme contrevenant à leurs conditions d'utilisations (bemaleficent et al., 2021; eBay, s. d.-a), et forcer l'usage de leur API afin d'accéder à

quelconque information sur leur plateforme. Cependant, comme discuté plus haut, l'usage de l'API peut présenter des dangers et des difficultés dans le maintien du logiciel.(Khder, 2021; Mancosu & Vegetti, 2020) De ce fait, lorsque face au détecteur de bot d'Amazon qui forçait la complétion d'un CAPTCHA avant d'afficher la page d'un article, on a essayé de se tourner vers des techniques qui donneraient l'impression que le navigateur ouvert par Selenium était opéré par un humain.(Asif et al., 2024; Lakshmi, 2023; Zenrows, 2023) Cependant, après tant d'essais d'accès automatisés à Amazon, l'adresse IP de notre machine avait accumulé une réputation négative auprès des détecteurs de bot d'Amazon (AWS, 2016; Lakshmi, 2023) et la seule solution possible qui semblait rester serait d'associer le logiciel à un RPV et de lancer les requêtes à travers un nouveau proxy pour chaque requête afin de ne jamais apparaître avec la même adresse IP.(thebotmaker, 2024) Même cette méthode ne garantissait pas que l'automatisation ne serait jamais détectée. Face à toutes ces mesures anti-automatisation, on a décidé de retirer Amazon des plateformes disponibles dans le logiciel, afin de garder le logiciel accessible pour les usagers qui n'ont pas les connaissances et l'expérience nécessaires afin de mettre en place les navigateurs et les RPV et proxy qui auraient été nécessaires au fonctionnement du logiciel.

Fonctionnalités non-implémentés

Comme expliqué plus haut, un des choix faits durant la conception des prototypes était de retirer la possibilité d'utiliser Amazon comme plateforme de vente des articles surveillés. Cette décision a été prise à cause des difficultés rencontrées face au détecteur d'automatisation d'Amazon. Afin de garder le logiciel accessible et facile d'installation et d'utilisation pour les utilisateurs, on a décidé de ne pas essayer de contourner le détecteur et de simplement retirer Amazon des plateformes de vente disponibles.

Ensuite, on s'est penché sur les demandes et suggestions que les utilisateurs ont faites durant les tests de fonctionnalité du prototype 2 qui ne sont pas implémentées. Une suggestion a été faite d'inclure des notifications vers d'autres services (e.g. : SMS, courriel, etc.) lorsqu'un des prix des articles surveillés changeait ou diminuait. Un tel système serait implémentable relativement facilement considérant la modularité de l'architecture du logiciel tel qu'il existe présentement. Cependant, il demanderait aussi l'implémentation (et donc l'apprentissage de l'utilisation et l'apprentissage du débogage) de plusieurs autres API et plug-ins. Il demanderait aussi la manipulation d'informations personnelles des usagers, tel que les numéros de téléphone, ce qui demande un certain niveau d'assurance de sécurité non implémenté dans le logiciel tel qu'il existe présentement. L'importance et la complexité de ces deux critères rendent l'ajout de cette fonction impossible dans la limite de temps imposée au projet.

Ensuite, les utilisateurs ont suggéré la possibilité de grouper les articles en différentes listes ou sous différents onglets, par exemple par thème ou pièce de la maison. Un tel changement est impossible dans le temps imparti, car il nécessiterait de presque complètement reconfigurer l'affichage de la page principale. Il nécessiterait aussi la présence de plus d'une liste d'articles dans le logiciel, ce qui complexifierait la vérification de doublons et l'écriture du fichier mémoire. Toute cette reprogrammation ne serait pas possible dans la limite de temps et n'aiderait pas les utilisateurs à accomplir les tâches énumérées pour le test de fonctionnalité, donc elle n'a pas été faite.

Une autre requête des usagers-testeurs qui aurait demandé beaucoup de reconfiguration était celle de pouvoir ordonner les articles selon différents attributs (e.g. : le prix, leur nom, etc.) et de pouvoir déplacer les articles dans la liste manuellement. Implémenter cette requête aurait nécessité de passer du type HashSet pour la liste à un type ordonnable par plusieurs attributs au

choix qui peuvent être modifiés et réordonner la liste alors que la liste existe déjà. Ceci aurait donc nécessité de reconfigurer la gestion de doublons aussi, puisque le HashSet a cette gestion déjà intégrée à son fonctionnement de manière élégante, et ce nouveau type de liste ordonnable pourrait nécessiter une gestion manuelle de doublons ce qui augmenterait la charge de travail nécessaire pour ce changement. En bref, ce changement demanderait beaucoup de temps pour reconfigurer des parties intégrales au logiciel pour un comparativement petit gain du côté utilisateur qui n'est pas nécessaire à la complétion des tâches de fonctionnalité.

Une des requêtes qui aurait juste demandé de modifier et ajouter à une classe existant était la requête de pouvoir cliquer sur l'image afin de l'agrandir, et même d'avoir accès à tout le catalogue d'image disponible sur la page web de l'article. Ces changements auraient demandé d'ajouter des attributs et des fonctions à Item et PagePrincipale, ainsi que de modifier les opérations Fetch et Write de ListeArticlesInteret. Ces changements auraient malheureusement demandé une plus grande connaissance de la manipulation et l'affichage d'image à travers java swing et java awt, ainsi que l'implémentation de beaucoup de nouveau code dans le projet, ce qui n'était pas réaliste avec la limite de temps imposée.

Finalement, la dernière suggestion des usagers-testeurs qui n'a pas été implémentée était l'ajout d'icônes à la place des mots pour les différents boutons disponibles aux usagers pour accomplir les différentes actions possibles dans le logiciel. L'utilisateur qui l'avait proposé expliquait que les icônes étaient plus faciles à naviguer pour lui et il les trouvait plus intuitifs. En effet, plusieurs études démontrent que l'humain comprend plus facilement, rapidement et intuitivement les icônes, et les icônes accompagnées d'un mot, que les mots seuls.(Gouin-Vallerand & Ruer, 2015b) Cependant, l'ajout d'icônes au logiciel nécessiterait la recherche d'images sous une licence ouverte qui pourraient être utilisées, ainsi que l'ajout et la

manipulation de ces fichiers dans le logiciel. Ces tâches relativement faciles n'étaient pas possibles dans les limites de temps, surtout puisqu'elles auraient eu un effet purement cosmétique sur le logiciel.

Méthodes d'évaluation

L'évaluation du logiciel porte sur trois facteurs : la fonctionnalité du logiciel, sa vitesse de traitement et l'exactitude des résultats qu'il obtient. En effet, la performance du logiciel ne peut pas être mesurée uniquement par sa vitesse d'exécution des tâches. (Bergman & Popov, 2023) Deux de ces trois caractéristiques peuvent être mesurées de manière empirique, ce qui est idéal pour le développement de logiciel. (Elmas, 2008) On favorisera des évaluations qualitatives afin d'analyser la fonctionnalité du logiciel et des évaluations quantitatives pour sa vitesse de traitement et son exactitude des résultats.

En ce qui concerne l'aspect fonctionnel, on s'adresse à une dizaine d'utilisateurs qui ont la chance d'utiliser directement le logiciel afin de juger par eux même à quel point les tâches de base, décrites à la figure 2, sont faciles à réaliser et qui ont ensuite à remplir un questionnaire de 30 questions décrivant leur expérience. Ce questionnaire porte sur leur capacité à réaliser ces tâches, mais aussi sur l'apparence et l'ergonomie du logiciel. Ils sont encouragés durant l'évaluation à donner des commentaires sur ce qui les dérange et ce qu'ils auraient aimé voir ou s'attendaient à voir dans le logiciel qui n'était pas présent.

L'évaluation de la vitesse de traitement est réalisée en gardant un enregistrement des horodates liés à différentes tâches et étapes de traitement afin de pouvoir être analysé séparément après l'utilisation du logiciel. Il a été nécessaire de créer une fonction complètement séparée du reste du logiciel qui est appelée à chaque fois qu'une tâche qui entre en contact avec une ressource externe au logiciel (eg. : la mémoire, une page web) est sur le point d'être appelée ainsi

qu'après la réalisation de la tâche. À chaque appel, cette fonction horodate le moment de son appel, de telle sorte à ce qu'on ait un horodate de début et de fin pour chaque tâche sous forme de milliseconde, puis enregistre ces horodates dans un fichier texte sous un format du type « nom de la tâche, start/end, type, horodate ». Ce fichier est ensuite manipulé dans par un script R afin de calculer les délais de temps pour chaque tâche et d'en ressortir les caractéristiques statistiques de base (minimum, maximum, moyenne, médiane). Ces caractéristiques sont nécessaires afin d'évaluer si les tâches sont accomplies à l'intérieur des délais déterminés comme acceptables, soit 10 secondes pour une tâche intra-machine et 30 secondes pour une tâche inter-machine. La récolte d'information à l'externe se voit accorder un plus long délai afin d'éviter d'être perçu comme un bot illégal par les plateformes de commerce électronique qui seront consultées.

(Bergman & Popov, 2023; Khder, 2021; Thelwall & Stuart, 2006)

Finalement, l'évaluation de l'exactitude des résultats est réalisée en comparant périodiquement les informations affichées par le logiciel à celles visualisables par l'humain sur les pages web des articles d'intérêt et en enregistrant le nombre d'affichages exacts et erronés en rapport au nombre d'articles observés total. On a identifié 40 items à surveiller sur eBay à travers plusieurs catégories, des accessoires pour animaux, aux véhicules motorisés, aux vêtements; et sur un grand éventail de prix, de quelques dollars à plusieurs milliers. Ces observations manuelles seront effectuées toutes les trois heures sur cinq jours consécutifs entre 11h00 et 1h00, pour un total de cinq observations par jour, donc 25 observations totales sur les 40 articles. À chaque observation, on note dans un fichier Excel la date et l'heure, ainsi que si une différence est présente entre l'information présentée par le logiciel et celle visualisable sur la page de l'article. À la fin de la période d'observation, le total de différences observées est comparé au total d'observation afin d'assurer que le taux d'exactitude du logiciel est de plus de 95%.

Évaluation du logiciel

Résultats de l'évaluation préliminaire (prototype 1 et 2)

Chaque prototype a été soumis à des versions mineures des méthodes d'évaluation du logiciel déterminées et explicitées dans la section précédente. Pour le prototype 1, on a décidé de tester l'exactitude du logiciel avec 30 items trouvés sur eBay à travers plusieurs catégories, durant trois jours; puis la fonctionnalité du logiciel en entrant ces articles manuellement et en testant toutes les fonctionnalités visibles sur le logiciel; et enfin la vitesse en enregistrant les délais de traitements de données tout au long du test d'exactitude. Pour le prototype 2, on a décidé de faire ces mêmes tests, mais cette fois-ci avec plus d'items et sur quatre jours pour l'exactitude, pour un total de 33 items, et avec trois vrais utilisateurs essayant de compléter les cinq tâches décrites à la figure 2, et les horodates récoltés pendant leur test pour tester la vitesse.

Exactitude

Sur les 450 observations manuelles comparatives faites sur le prototype 1, on n'a remarqué que deux erreurs d'affichage, et on a rapidement compris que celles-ci étaient dues au mal fonctionnement de la mise à jour automatique. De ce fait, le taux d'exactitude minimale de 95% est plus qu'atteint avec un taux d'exactitude de 99.5%. Pour le prototype 2, on a décidé d'agrandir de la liste d'item surveillé de 3 et d'enregistrer les observations comparatives sur 4 jours, pour un total de 627 observations. Sur ces 627 observations des prix, une seule s'est retrouvée à être inexacte, pour un taux d'exactitude de 99.8%. Cependant, durant le test, on a remarqué qu'eBay n'indique pas qu'un item est en rupture de stock en lui retirant son prix, mais plutôt en ajoutant un ruban à sa page d'annonce. De ce fait, certains items qui étaient en rupture de stock avaient été lus par le logiciel et par le vérificateur comme affichant la même information

sur la page et sur le logiciel, alors que ce n'était pas vraiment le cas. On ne peut donc pas utiliser de façon définitive les taux d'exactitude des prototypes 1 et 2.

Vitesse

Lorsqu'on a passé le fichier d'horodatage des tâches dans le script R, on a remarqué beaucoup de données aberrantes. Celles-ci semblent être le produit de quelques bogues rencontrés durant le test d'exactitude, par exemple lorsque la machine tombait en veille durant une mise à jour des données. Ces données affectaient grandement la moyenne, donc on ne l'utilise pas pour déterminer si les limites de temps étaient respectées dans ce test. Cependant, en s'en tenant aux médianes, on remarque un délai de 0.05 seconde pour le traitement de données intra-machine, et un délai de 0.30 seconde pour celui inter-machine, ce qui est considérablement sous les minimums explicités plus tôt.

Le test de vitesse du prototype 2 a été effectué sur les données recueillies durant les tests de fonctions par les trois sujets mentionnés précédemment. Ces données ont été transformées par le même script qu'avec le prototype 1. On y a remarqué moins de données aberrantes, bien qu'il en reste tout de même. Les moyennes étant encore trop affectées par ces données, étant de 30.8 secondes pour les traitements intra-machines et de 14.960 secondes pour ceux inter-machines, on s'est concentré sur les médianes, qui étaient de 0.01 seconde pour les traitements intra-machine et 4.874 secondes pour ceux inter-machines, ce qui est à l'intérieur des limites explicitées plus tôt. Lors de la revue des données afin de comprendre d'où les données aberrantes provenaient, on a remarqué que beaucoup des opérations qui étaient interrompues par une erreur se retrouvaient à ne pas être déclarées comme terminées, ce qui poussait le script à chercher la prochaine opération du même nom et prendre son horodate de fin afin de calculer la durée de l'opération. Ceci pouvait donner à une tâche de quelques secondes qui avait généré une erreur l'apparence

d'une tâche de plusieurs heures, rendant ainsi le fichier de données brutes incomplet et les résultats de l'analyse du script inexacte. Cette erreur a été rectifiée dans le produit final.

Fonctionnalité

Le plus gros problème de fonctionnalité qui a été rencontré dans le prototype 1 était que l'affichage des fenêtres était trop petit, malgré l'usage de la fonction `pack()` de Java Swing qui aurait dû forcer la taille de chaque fenêtre afin qu'elles soient assez grandes pour que toutes les composantes soient visibles. Cette erreur cachait certains boutons et champs à l'utilisateur, et il fallait agrandir les fenêtres manuellement afin d'avoir accès aux boutons. À part ce problème, toutes les autres fonctions attendues et nécessaires à l'accomplissement des tâches étaient présentes et fonctionnaient comme attendu.

Pour le test de fonctionnalité du prototype 2, on a laissé trois sujets essayer le logiciel afin d'accomplir les tâches de la figure 2, puis en donnant leurs opinions à travers le questionnaire mentionné plus tôt. Tous les sujets ont été capables de compléter les tâches demandées dans un délai de moins de 10 minutes et ils avaient tous des opinions majoritairement positives du logiciel selon leurs réponses au questionnaire de satisfaction, avec une moyenne de 21.5 réponses positives sur les 30 questions, cependant ils avaient tous des suggestions et commentaires sur comment le logiciel aurait pu leur faciliter la tâche, et ils ont aussi découvert certains bogues.

La majorité de leurs suggestions ont été implémentées dans le logiciel final. On peut mettre en évidence les suggestions plus cosmétiques, tel la requête d'un mode sombre et de l'agrandissement de la police d'écriture, ainsi que l'ajout d'infobulles pour les différents champs et boutons. Pour ce qui est des bogues mentionnés, on a découvert que certains utilisateurs seraient tentés de fermer rapidement les fenêtres que Selenium ouvre afin de lire

l'information sur les articles, ce qui causait au logiciel de ne pas pouvoir fonctionner correctement. On a ajouté des messages prévenant l'utilisateur de ne pas toucher à ces fenêtres et un message d'erreur spécialisé qui s'affiche si l'utilisateur ferme quand même une fenêtre ouverte par Selenium. On a aussi découvert que de fermer les fenêtres d'ajout et de modification d'item en cliquant sur le X fermer l'intégralité du logiciel au lieu d'uniquement fermer la fenêtre en question. On a donc rectifié le code pour empêcher ce problème de se produire.

Résultat de l'évaluation final

On a dû tester le logiciel en deux temps, car, durant les tests d'exactitude et de fonctionnalité, eBay a reconfiguré le format sous lequel il stocke ses images. Le nouveau format, WebP, n'étant pas natif à Java, il a fallu ajouter une librairie d'appoint au logiciel, TwelveMonkeys (Kuhr, 2024), et le recompiler et renvelopper avant de pouvoir poursuivre les tests. Ce changement n'a aucunement affecté la fonctionnalité du logiciel, donc les témoignages des utilisateurs testeurs ont toujours tous autant de valeur. Il a uniquement affecté la capacité du logiciel à afficher les images des items surveillés lorsque cette habilité a été compromise par la plateforme de vente.

Exactitude

Le taux d'exactitude des observations comparatives manuelles est de 99.2%. En effet, on n'a observé que 8 erreurs sur les 1,000 observations faites au total. Ces erreurs observées étaient dispersées à travers le temps et à travers les articles observés. On remarque donc que le taux d'exactitude est largement supérieur au minimum de 95% exigé et est pratiquement parfait. Cependant, on a remarqué avec deux articles en particulier que, lors de l'ouverture du logiciel, celui-ci ne semblait pas mettre à jour les informations des articles et affichait seulement les informations qui avaient été enregistrées lors de la dernière utilisation. Ceci ne causait pas de

grand problème lors d'une évaluation telle celle faite ici, où on observe les articles sur quelques jours consécutifs et durant plusieurs heures, ce qui permet au logiciel de se rattraper. Mais, si on n'ouvrait le logiciel que de temps en temps et qu'on se fiait aux informations qu'il affichait afin de vraiment surveiller des prix importants, cet accrochage dans le code pourrait être plus problématique. De plus, on a remarqué, avec un autre article, que si un article tombait en rupture de stock alors qu'il avait été ajouté à la liste quand il était encore en stock, le logiciel n'affichait pas l'étiquette rupture de stock tel qu'on la voyait sur les articles qui avait été ajouté alors qu'ils étaient déjà en rupture de stock.

Vitesse

Durant les tests qui ont été faits avec le produit final, on a récolté les horodates des opérations où le logiciel entraient en contact avec la mémoire et avec une page web. En passant ces données dans le script R mentionné précédemment, on a calculé que le délai moyen pour les opérations intra-machine était de 26.58 secondes, avec une médiane de 0.0165 seconde. Cette moyenne dépasse la limite de 10 secondes imposées, mais cette médiane est largement à l'intérieur de cette limite. De plus, on a un temps minimal de 0.001 seconde et un maximum de 230.4 secondes qui dépasse considérablement le maximum imposé. Pour les opérations inter-machines, on a calculé une moyenne de 8.615 secondes et une médiane de 8.680, qui sont tous deux largement à l'intérieur de la limite de 30 secondes imposée. On a aussi extrait un minimum de 0.004 seconde et un maximum de 25.14 secondes, qui sont eux aussi à l'intérieur de la limite de 30 secondes.

Fonctionnalité

Les utilisateurs-testeurs ont tous utilisé le logiciel afin d'accomplir les tâches explicitées à la figure 2. Ils ont tous réussi à accomplir les tâches en moins de 15 minutes et avaient tous des

opinions majoritairement positives à propos de leur expérience. En effet, ils ont répondu positivement à 24.45/30 questions en moyenne, et aucun d'entre eux n'a eu moins de 20/30 réponses positives. De toutes les observations et requêtes que le questionnaire a soulevées, on peut en mettre en évidence quelques-unes.

Tout d'abord, un des utilisateurs a découvert un bogue lorsqu'on essayait d'entrer un URL qui était simplement une suite de caractère aléatoire. En effet, lorsqu'on entrait quelque chose comme « uuuu » dans le champ de l'URL de la fenêtre d'ajout d'un article, le logiciel essayait de l'ouvrir, et l'absence de quoique ce soit dans la page était perçu comme une incapacité de la part du logiciel de percevoir des éléments, donc il déduisait que l'utilisateur devait avoir fermé la page web avant qu'il ne puisse la lire. Cette confusion en termes d'erreur peut être corrigée dans le code et n'obstrue pas à la capacité du logiciel à collecter l'information la plus récente et l'afficher, donc ce n'est pas un bogue majeur.

Les utilisateurs avaient plusieurs commentaires et observations face au logiciel. Tout d'abord, beaucoup d'utilisateurs ont noté que les seules erreurs qu'ils se voyaient commettre étaient des erreurs de frappe lors de l'entrée des nom et description ou de l'entrée de l'URL. Beaucoup d'entre eux ont aussi noté que les mises à jour ne peuvent pas être interrompues et peuvent être distrayantes et lentes à cause du nombre de fenêtres qui s'ouvrent et se ferment de manière visible à l'utilisateur. Deux utilisateurs plus vieux ont noté que le choix de plateforme de vente aurait pu être plus judicieux puisqu'eBay n'est pas particulièrement facile à utiliser pour les non-initiés, et que ce ne sont pas tous les utilisateurs qui sauraient ce qu'est un URL et où le trouver sur l'écran. Finalement, un utilisateur a noté qu'il semblait inutile au logiciel d'ouvrir des fenêtres et de mettre à jour les informations s'il modifiait uniquement le nom ou la description de l'item.

Ensuite, les utilisateurs avaient tous beaucoup de requêtes quant à ce qu'ils auraient aimé voir dans le logiciel. En ce qui concerne l'interface graphique, les utilisateurs auraient aimé pouvoir augmenter la taille de la police à travers le logiciel et augmenté la taille de l'image temporairement. Beaucoup d'entre eux auraient aimé que les boutons et les composantes aient des couleurs plus variées et soient accompagnés de symboles ou d'icônes. Un utilisateur a mentionné qu'il serait intéressant que les prix restent affichés même lorsqu'un item est en rupture de stock, et un autre a mentionné qu'il serait pertinent d'ajouter un onglet de menu afin de regrouper les options de personnalisation de l'affichage. Enfin, deux utilisateurs ont mentionné qu'il faudrait ajouter un message invitant l'utilisateur à trouver un article sur eBay avant de lui offrir la page de création d'item.

Les utilisateurs avaient aussi beaucoup de suggestions quant aux fonctionnements du logiciel. Un des utilisateurs qui travaille en développement informatique a, par exemple, mentionné qu'il serait judicieux d'inverser les boutons lors de la confirmation de la suppression afin de forcer l'utilisateur à bouger sa souris ou peser des boutons de plus sur le clavier avant de réellement supprimer un article. On s'est aussi fait mentionner qu'il serait pertinent d'ajouter plus d'options d'ordonnancement des items, et qu'il aurait été plus intuitif que, par défaut, les items soient ordonnés par date et moment d'ajout. Un utilisateur nous a aussi mentionné qu'il serait judicieux d'offrir une option permettant de ne plus afficher les avertissements d'ouverture de fenêtre. Un autre utilisateur a mentionné qu'il faudrait ajouter une option afin de lui permettre de sauvegarder la liste d'item sans quitter, et qu'il faudrait instaurer un système d'auto-sauvegarde sur une minuterie comme celui d'auto-mise à jour.

En ce qui concerne spécifiquement les mises à jour des informations, les utilisateurs avaient tous des opinions et des suggestions. En effet, ils trouvaient tous cela déstabilisant que

des fenêtres s'ouvrent et se ferment sans leur contrôle. Certains ont suggéré de garder les mises à jour derrière la fenêtre du logiciel, ou de tous simplement rendre les fenêtres du navigateur invisibles. D'autres ont suggéré d'au moins mettre un avertissement lorsqu'une mise à jour automatique est imminente. De plus, un utilisateur a mentionné qu'il serait pertinent d'offrir la mise à jour d'article individuelle. D'ailleurs, un utilisateur a été confus par le fait que le logiciel ouvre et ferme des fenêtres afin de mettre à jour des informations alors qu'il avait uniquement modifié le nom d'un item, et il a suggéré que, dans le cas où le champ modifier n'est pas l'URL, le logiciel offre de mettre à jour les autres informations, mais qu'il ne le fasse pas par défaut.

Appréciation des résultats de l'évaluation

Si on considère les taux d'exactitude des prototypes et du produit final, on peut affirmer que le logiciel réussit à collecter et afficher des informations exactes. En effet, les taux d'exactitude de 99.5%, 99.8% et 99.2% démontre une capacité bien meilleure que le 95% imposé au logiciel. Ces résultats sont tous extrêmement proches du 100%, donc la marge d'erreur du logiciel est extrêmement mince. Si on exclut les résultats des prototypes, puisqu'il ne prenait pas en compte les articles en rupture de stock, on se retrouve tout de même avec un taux d'exactitude plus près du 100% que de la limite minimal de 95%. De plus, on peut affirmer que la section ajoutée au logiciel qui lui permet de détecter les ruptures de stock fonctionne relativement bien, car on a observé des articles changés de statuts et de prix durant ce test. De ces faits, on peut affirmer que le logiciel est exact dans sa récolte et son affichage de l'information.

D'après les tests de vitesses qui ont été faits, on remarque que la majorité du temps le logiciel est capable de compléter ses opérations dans les limites imposées. En effet, pour le produit final, on remarque que la moyenne et la médiane des opérations inter-machine sont largement sous la limite de 30 secondes imposée. Même le délai maximal enregistré des

opérations inter-machines est de moins de 30 secondes. Ces observations peuvent aussi être faites pour les médianes des prototypes. On peut donc affirmer que dans plus de la moitié des opérations inter-machine des prototypes, on respectait la limite de temps, et que dans toutes les opérations inter-machine du produit final, on respectait la limite de temps. Cependant, pour les opérations intra-machine, on n'obtient qu'une médiane qui est à l'intérieur de la limite de 10 secondes imposée. En effet, le maximum et la moyenne sont de beaucoup plus que 10 secondes, avec une moyenne qui est plus proche du 30 secondes imposé aux opérations inter-machines. Ce problème est aussi présent dans les évaluations faites sur les prototypes, même si on prend en compte les erreurs d'enregistrement qui se produisaient avec ces versions. Il est intéressant d'observer que dans toutes les versions du logiciel les communications intra-machine semblent toujours prendre plus de temps que les communications inter-machine, peu importe la caractéristique statistique qu'on compare. Bref, on peut affirmer que le logiciel respecte les limites de temps imposées pour les opérations inter-machine mais pas pour les opérations intra-machine, donc ce n'est qu'un demi-succès pour ce critère.

En ce qui concerne le fonctionnement, on peut affirmer que le logiciel fonctionne comme attendu et qu'il répond aux attentes des utilisateurs. En effet, le questionnaire cherchait à donner la chance au logiciel d'être critiqué, et les utilisateurs ont tout de même eux des réponses majoritairement positives. De plus toutes les suggestions qu'ils ont proposées seraient réalisables et amélioreraient la convivialité et l'accessibilité du logiciel pour les utilisateurs. En effet, si on prend en exemple les requêtes d'ajout de couleur plus variée et de symboles sur les composantes de l'interface graphique, ceci permettrait de rendre le logiciel plus accessible aux utilisateurs ayant une déficience visuelle ou souffrants de daltonisme. Les requêtes d'agrandissement de la police et des images dans le logiciel serviraient cette même fonction en plus de rendre le logiciel

plus personnalisable pour tous. Un des utilisateurs avait d'ailleurs mentionné qu'une police trop petite pourrait pousser certains utilisateurs pressés à ignorer certaines fenêtres ce qui pourrait causer des erreurs. Du côté du modèle et des contrôleurs sous-jacents aux vues, les requêtes d'ajouter une option de sauvegarde et de mettre en place une auto-sauvegarde sur une minuterie sont aussi faciles à ajouter à l'implémentation déjà présente de l'auto-mise à jour et permettraient d'assurer la minimisation de perte de données si le logiciel ou la machine cessait soudainement de fonctionner. Un autre exemple serait l'ajout de l'offre de mise à jour d'article individuelle, pour laquelle l'implémentation ne requerrait principalement que de la réutilisation de code et qui permettrait à l'utilisateur de contrôler de plus près sa surveillance de ses articles. Cependant, même sans l'implémentation de toutes les requêtes des utilisateurs-testeurs, ceux-ci ont conclu que le logiciel était fonctionnel et était un succès sur le plan de ce critère.

Conclusion

Le présent rapport détaille les pratiques d'exploration et de récolte automatisée du web, et utilise la récolte automatisée afin de développer un logiciel qui assiste les utilisateurs dans leur magasinage sur eBay. Selon les critères d'évaluations appliqués au logiciel, on affirme que son développement fût un succès et qu'il accomplit toutes les tâches qu'on avait définies pour lui. Cependant, il pourrait être amélioré. En effet, un des problèmes le plus fréquemment identifiés par les utilisateurs-testeurs était que l'ouverture et la fermeture des fenêtres dans un navigateur web visible étaient dérangeantes. Ceci pourrait être minimisé en utilisant l'envoi de requête POST à l'URL des articles. (Dakov & Malinova, 2021) Ceci permettrait de récolter les informations des articles sans jamais avoir à ouvrir une fenêtre de navigateur web, ce qui rendrait l'application moins demandante en ressource en plus d'être plus conviviale pour l'utilisateur. De plus, il serait intéressant d'explorer la possibilité de développer un récolteur automatisé plus

généralisé capable de récolter de l'information sur plusieurs plateformes de commerces différentes. (Dakov & Malinova, 2021)

Il serait aussi intéressant de se pencher sur l'usage d'API de plateforme de commerce lors de la récolte d'information et de développer une solution informatique qui combine la récolte automatisée et l'usage d'API pour une ou plusieurs plateformes de commerce. Ceci permettrait d'intégrer Amazon au logiciel, ce qui serait judicieux considérant la popularité de la plateforme. La réutilisation du code développé pour ce projet serait idéale pour le développement de cette solution, ne serait-ce que pour l'interface graphique avec laquelle l'utilisateur interagit. (Khder, 2021) La dépendance à la disponibilité de l'API ne serait évidemment pas idéale (Mancosu & Vegetti, 2020), mais elle ne serait pas plus dangereuse que la dépense de la présente application au format HTML des pages de la plateforme couverte. En effet, le fait qu'on ait dû interrompre les tests de l'application afin de reconfigurer comment certaines informations étaient lues à cause du changement de format des données effectué par eBay, démontre qu'aucune méthode n'est complètement protégée des changements et décisions prises par la plateforme sur laquelle les données recherchées se trouvent.

Bref, l'équilibre entre les plateformes se faisant récolter et les récolteurs automatiques est en constante évolution depuis le commencement de la pratique. Les nouveautés de chaque côté ne cesseront de continuer de se développer tant que ces pratiques ne seront pas encadrées d'un cadre légal strict, clair et explicite qui prend en considération les récolteurs de données et le bien qu'ils peuvent faire ainsi que les plateformes où les données sont récoltées et leur transparence. Même un tel cadre n'empêcherait pas des récolteurs motivés et malintentionnés. Il convient donc d'éduquer les plateformes et les utilisateurs à propos des bien fait et de méfaits possibles que la récolte automatisée produit et comment chacun peut être affecté par ce genre de pratiques.

Bibliographie

- Acuña, J. (2022, mai 21). *Web Scraping on Amazon with Selenium[Python]*.
<https://kaggle.com/code/jesusacunamorillo/web-scraping-on-amazon-with-selenium-python>
- AdsPower. (2024, mars 18). A Step-by-Step eBay Scraping Guide. *AdsPower*.
<https://www.adspower.com/blog/a-step-by-step-ebay-scraping-guide>
- Asif, S. M. Z., Gul Solangi, F., Kumar, S., Mansoor, N., & Bano, S. (2024). Optimizing Product Findings in E-commerce by Selenium and Naive Bayes Approach. *SSRN Electronic Journal*. <https://doi.org/10.2139/ssrn.4708255>
- AWS. (2016, décembre 1). *Amazon Pinpoint*. Amazon Web Services, Inc.
<https://docs.aws.amazon.com/pdfs/pinpoint/latest/userguide/pinpoint-ug.pdf#channels-email-deliverability-dashboard-ip-address>
- bemaleficent, Gidoneli, LeiterHaus, & kronos-arcanum. (2021, février 20). *Is scraping Amazon legal?* [Reddit Post]. R/Webscraping.
www.reddit.com/r/webscraping/comments/lo25dq/is_scraping_amazon_legal/
- Bergman, J., & Popov, O. B. (2023). Exploring Dark Web Crawlers : A Systematic Literature Review of Dark Web Crawlers and Their Implementation. *IEEE Access*, 11, 35914-35933. <https://doi.org/10.1109/ACCESS.2023.3255165>
- Bettenbuk, Z. (2021, mars 4). Is Web Scraping Legal? The Complete Guide. *ScraperAPI*.
<https://www.scraperapi.com/blog/is-web-scraping-legal/>
- Dakov, S., & Malinova, A. (2021). AUTOMATED PRODUCT INFORMATION RETRIEVAL IN E-COMMERCE. *International Journal of Differential Equations and Applications*, 20(2), 157-168. <https://doi.org/10.12732/ijdea.v20i2.2>

- de Mereuil, A., & Bonnefous, A.-M. (2016). Anatomie d'une cyber-attaque contre une entreprise : Comprendre et prévenir les attaques par déni de service. *Annales des Mines - Gérer & comprendre*, 123(1), 5-14. <https://doi.org/10.3917/geco1.123.0005>
- Dilmegani, C. (2024, janvier 17). *Top 5 e-Commerce Web Scraping Use Cases in 2023*. AIMultiple: High Tech Use Cases & Tools to Grow Your Business. <https://research.aimultiple.com/web-scraping-ecommerce/>
- eBay. (s. d.-a). *User Agreement*. eBay. Consulté 8 août 2024, à l'adresse <https://www.ebay.com/help/policies/member-behaviour-policies/user-agreement?id=4259>
- eBay. (s. d.-b). *Violation of the eBay User Agreement policy*. eBay. Consulté 8 août 2024, à l'adresse <https://www.ebay.ca/help/policies/member-behavior-policies/violation-ebay-user-agreement-policy?id=4371>
- Elmas, T. (2008). *The core evaluation of a software engineering research result*.
- Gouin-Vallerand, C., & Ruer, P. (2015a, mars). *Activité 1 – Approche Modèle-Vue-Contrôleur (MVC) | inf1420*. <https://inf1420.teluq.ca/semaine-10/activite-1-approche-modele-vue-controleur-mvc/>
- Gouin-Vallerand, C., & Ruer, P. (2015b, mars). *Activité 2 – Concepts de conscience et d'inconscience dans les IHM | inf1420*. <https://inf1420.teluq.ca/semaine-2/activite-2/>
- imperva. (s. d.). What Is Scraping | About Price & Web Scraping Tools | Imperva. *Learning Center*. Consulté 15 mars 2024, à l'adresse <https://www.imperva.com/learn/application-security/web-scraping-attack/>
- Khder, M. (2021). Web Scraping or Web Crawling : State of Art, Techniques, Approaches and Application. *International Journal of Advances in Soft Computing and its Applications*, 13(3), 145-168. <https://doi.org/10.15849/IJASCA.211128.11>

- Kowal, G. (2022). *Launch4j—Cross-platform Java executable wrapper* (Version 3.50) [C, Java; Solaris, Linux, Mac, Windows]. <https://launch4j.sourceforge.net/index.html>
- Kuhr, H. (2024). *TwelveMonkeys ImageIO by haraldek* (Version 3.11.0) [Software]. <https://haraldek.github.io/TwelveMonkeys/>
- Lakshmi, A. (2023, novembre 6). Is Scraping Amazon Legal? Tips and Considerations. *ScraperAPI*. <https://www.scraperapi.com/blog/amazon-web-scraping-policy/>
- Mancosu, M., & Vegetti, F. (2020). What You Can Scrape and What Is Right to Scrape : A Proposal for a Tool to Collect Public Facebook Data. *Social Media + Society*, 6(3), 205630512094070. <https://doi.org/10.1177/2056305120940703>
- Morello, P. (2024, mai 9). Is It Legal To Scrape E-Commerce Websites? *Pricefy*. <https://www.pricefy.io/articles/legal/is-it-legal-to-scrape-ecommerce-websites/>
- Mozilla. (2023, octobre 16). *HTML - Glossaire MDN : Définitions des termes du Web | MDN*. mdn web docs. <https://developer.mozilla.org/fr/docs/Glossary/HTML>
- Perez, M. (2020, mars 9). Web Scraping vs API : What's the Difference? *Web Scraping Blog (Tips, Guides + Tutorials) | ParseHub*. <https://www.parsehub.com/blog/web-scraping-vs-api/>
- Radware. (2022). *Price Scraping | Definition, Impact & Prevention | Radware*. <https://www.radware.com/cyberpedia/bot-management/price-scraping/>
- Tauber, K. (2024). *FlatLaf—Flat Look and Feel | FormDev* (Version 3.5.1) [Java]. FormDev Software GmbH. <https://www.formdev.com/flatlaf/>
- thebotmaker. (2024, février 7). *Evading Selenium Detection : The Ultimate Guide* [Post]. BlackHatWorld. <https://www.blackhatworld.com/seo/evading-selenium-detection-the-ultimate-guide.1569690/>

Thelwall, M., & Stuart, D. (2006). Web crawling ethics revisited : Cost, privacy, and denial of service. *Journal of the American Society for Information Science and Technology*, 57(13), 1771-1779. <https://doi.org/10.1002/asi.20388>

Zenrows. (2023, octobre 14). How to Avoid Bot Detection with Selenium—ZenRows. *Zenrows*. <https://www.zenrows.com/blog/selenium-avoid-bot-detection>

Annexes

Annexe 1 – Test de fonctionnalité du produit final

Résultats de satisfaction selon le questionnaire:

Usager	Note
1	24.5/30
2	21.5/30
3	27.5/30
4	25/30
5	24.5/30
6	25.5/30
7	26.5/30
8	27/30
9	20/30
10	22.5/30
Moyenne	24.45/30

Commentaires et suggestions :

- Usager 1 :
 - Requêtes : automatiquement placer le curseur dans le champ nom lors de l'ouverture des fenêtres ajout et modifier, ajouter des couleurs sur les différents boutons, augmenter la taille de la police dans les fenêtres JDialog
 - Observations : logiciel est lent, eBay n'est pas facile pour les non-initiés,
- Usager 2 :
 - Requêtes : la confirmation de la suppression ne devrait pas être l'option sélectionner pas défaut pour éviter les suppressions trop rapides (demande à l'utilisateur de peser plus de boutons donc lui laisse plus de temps pour penser et réagir)

- Observations : ce ne sont pas tous les usagers qui savent ce qu'est une URL et où le trouver, l'ouverture et la fermeture des fenêtres de navigateur est à la fois distrayantes et cool
- Bogue découvert : si aucune URL n'est entrée à la sauvegarde, le logiciel réagit comme si l'utilisateur avait fermé la fenêtre durant la lecture des informations
- Usager 3 :
 - Requêtes : augmenter la taille de la barre de menu, garder le logiciel au premier plan durant les ouverture et fermeture de fenêtre (décourage l'utilisateur de fermer les fenêtres pendant que le logiciel les utilise)
 - Observations : mise à jour ne peut pas être interrompue à n'importe quel moment, seules erreurs possibles sont les fautes d'orthographe
- Usager 4 :
 - Requêtes : s'assurer que les fenêtres ouvertes sont dans le même espace que la fenêtre principale occupe, donner un avertissement que le logiciel va automatiquement mettre à jour des informations (les fenêtres qui ouvrent toutes seules font peur), ajouter des symboles/icônes sur les boutons, indiquer le mode sombre/clair avec des symboles de lune/soleil par exemple
 - Observations : possible de mal sélectionner URL
- Usager 5 :
 - Requêtes : afficher le prix de l'item même s'il est en rupture de stock, offrir à l'utilisateur l'option de ne plus afficher les popups pour le reste de la session d'utilisation, permettre de voir l'image en plus grand en cliquant dessus, ajouter

un onglet de menu pour l'affichage, y permettre d'agrandir et de rapetisser la police et y mettre les options de thèmes

- Observations : les mises à jour ne peuvent pas être interrompues
- Usager 6 :
 - Requêtes : rendre les mises à jour invisibles (ou au moins les garder en arrière du logiciel) et mettre une barre de chargement pour indiquer qu'on est en train de mettre à jour les informations, offrir une mise à jour d'un article individuel, pouvoir sauvegarder la liste sans quitter, avoir une auto-sauvegarder sur un minuteur comme l'auto-mise à jour
 - Observations : possible de mal entrer l'URL ou d'entre quelque chose qui n'est pas une URL (voir bogue de l'utilisateur 2)
- Usager 7 :
 - Requêtes : ajouter des couleurs sur les boutons, MAIS assurer l'accessibilité pour les daltoniens avec des formes ou des symboles, les fenêtres qui ouvrent et ferment rendent flous quand est-ce qu'on retourne au logiciel on pourrait les cacher derrière une fenêtre disant « Travail en cours »
 - Observation : l'entrée de données manuelle crée un risque d'erreur inhérent
- Usager 8 :
 - Requêtes : dire à l'utilisateur de trouver un item sur eBay avant de lui afficher la fiche d'ajout, les fenêtres qui ouvrent et ferment sont trop distrayantes il faudrait les cacher
 - Observations : ne peut pas interrompre une mise à jour en cours

- Usager 9 :
 - Requête : il faudrait dire à l'utilisateur de trouver un item sur eBay avant de lui montrer la fenêtre d'ajout, le copier-coller de l'URL rend la création d'item plus difficile
 - Observations : s'attend à ce qu'un clic sur l'image ouvre une fenêtre de navigateur qui affiche la page web de l'article, le logiciel est lent, ne peut pas interrompre les mises à jour
- Usager 10 :
 - Requête : ordonner les articles chronologiquement par leur ajout, offrir plus d'options d'ordonnement des items, vérifier si l'URL a été modifiée puis offrir à l'utilisateur de mettre à jour les informations si non afin de ne pas ouvrir des fenêtres si on a juste modifié le nom par exemple,
 - Observations : pourquoi ouvrir des fenêtres de navigateur si seulement le nom ou la description ont été changés, ouverture des fenêtres est distrayant dans tous les cas, mais surtout si on ne s'y attend pas, on peut commettre des erreurs, mais on peut toujours les corriger puisque les messages d'erreur avertissent l'utilisateur

Annexe 2 – Test de vitesse du produit final

```
> summary(delayintra$Delay)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
1.000	4.250	16.50	26580.	10250.	2.304e+5


```
> summary(delayinter$Delay)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
4.000	5997.	8680.	8615.	11060.	25140.

Annexe 3 – Test d’exactitude du produit final

[illegible]

Annexe 4 – Architecture du produit final



Annexe 5 – Glossaire de traduction

Anglais	Français
Web crawling	Exploration du web automatisée
Web scraping	Récolte de page web automatisée
Information retrieval	Récupération d'information
Parse	Analyser
Screen scraping	Récolte d'écran automatisé
Regular expression/RegEx	Expression régulière
Computer vision	Vision par ordinateur
Pay wall	Verrou d'accès payant
Framework	Cadre
Package	Paquetage
Screen-scraping	Récolte d'affichage à l'écran
Browser	Navigateur
VPN (Virtual Private Network)	RPV (Réseau privé virtuel)
Wrapper	Enveloppeur
Timestamp	Horodate
Tooltip	Infobulle